#### HENRY



### Formatos de almacenamiento





- Comprender las características de los distintos formatos de almacenamiento.
- Entender los factores de elección del formato de almacenamiento.
- Usar las herramientas de compresión de datos de Hadoop.









> Formatos de almacenamiento

> Factores de elección

⇒ CSV

**⇒** JSON

Avro

Parquet

> Herramientas de comprensión de datos

# Formatos de almacenamient



#### FORMATOS DE ALMACENAMIENTO

La elección de un formato correcto puede traducirse en mejoras de performance y reducción de costos.

**Big Data** 

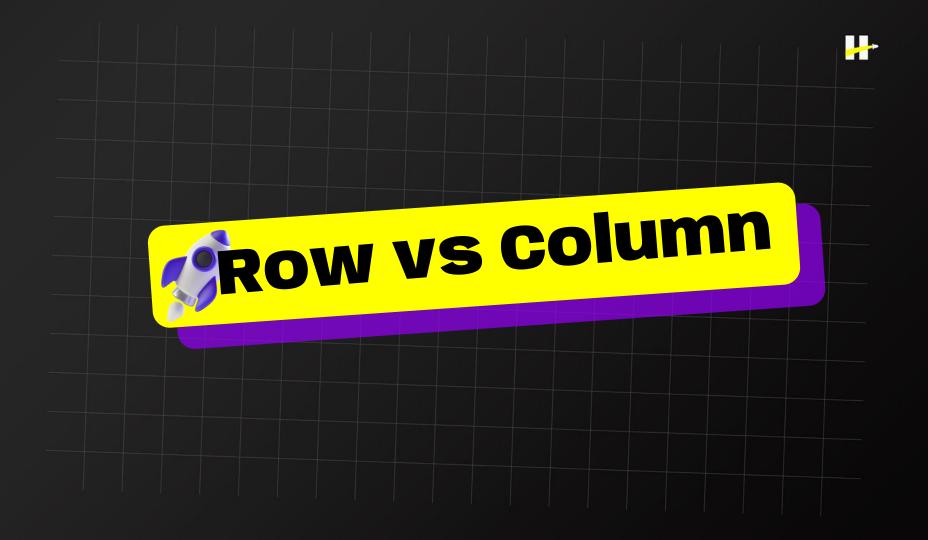








# Factores de elección



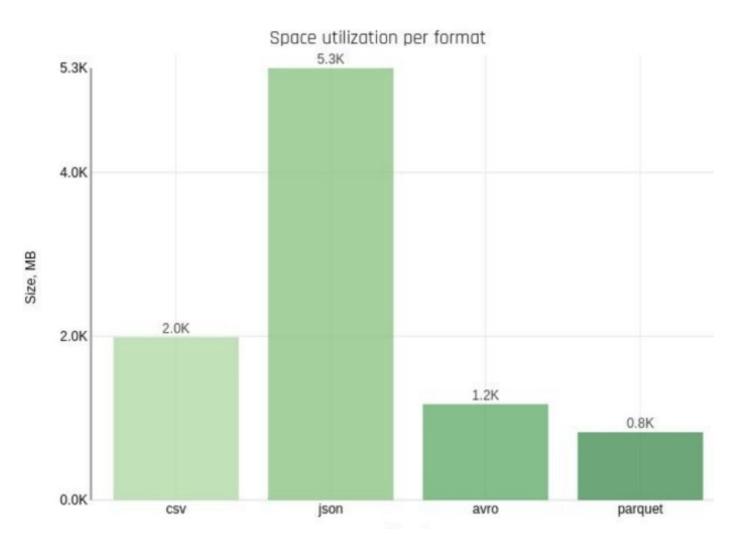
	day	location	product	sale
row 1	2017-01-01	I1	р1	300
row 2	2017-01-01	l1	p2	40
row 3 row 4	2017-01-01	12	p1	44
	2017-02-01	<b>I</b> 1	p1	200

	Memory Buffer 2017-01-01		
row 1	11		
	p1		
	300		
row 2	2017-01-01		
	l1		
10W 2	p2		
	40		
	2017-01-01		
row 3	12		
	p1		
	44		

Column	ar Storage		
	2017-01-01		
day	2017-01-01		
uay	2017-01-01		
	2017-01-02		
	11		
location	1		
location	12		
	l1		
	p1		
product	p2		
	p1		
	p1		











Texto plano delimitado por el carácter de la coma (pueden utilizarse otros separadores). Generalmente este formato lo utilizan aplicaciones tradicionales para exportar datos hacia otros sistemas.

<b>4 &gt;</b>	austin_bikeshare_stations.csv ×
1	latitude,longitude,name,station_id,status
2	30.27041,-97.75046,West & 6th St.,2537,active
3	30.26452,-97.7712,Barton Springs Pool,2572,active
4	30.27595,-97.74739,ACC - Rio Grande & 12th,2545,closed
5	30.2848,-97.72756,Red River & LBJ Library,1004,closed
6	30.26694,-97.74939, Nueces @ 3rd,1008, moved
7	30.26751,-97.74802,Republic Square,2500,moved
8	30.24891,-97.75019,South Congress & Elizabeth,2504,active
9	30.26461,-97.73049,Waller & 6th St.,2536,closed
10	30.26217,-97.72743,Plaza Saltillo,2542,active
11	30.28576,-97.74181,UT West Mall @ Guadalupe,2548,active





JSON (JavaScript Object Notation) es un formato ligero y legible por humanos utilizado para intercambiar y almacenar datos estructurados.





Almacena los datos en formato binario para reducir el tamaño y mejorar la performance. La definición de los datos (schema) se almacena en formato JSON. Es recomendable utilizarlo para consultas de tipo SELECT \*.

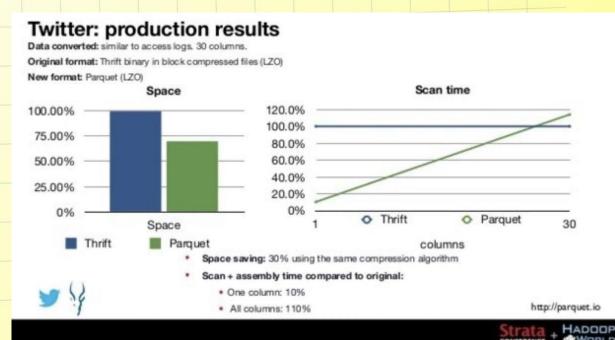
```
{
    "id": 123,
    "first": "ben",
    "last": "goldberg",
    "email": "ben@email.io",
    "phone": "1234567890",
    ...
}

**fields": [
    {"name": "id", "type": "int"},
    {"name": "first", "type": "string"},
    {"name": "last", "type": "string"},
    {"name": "email", "type": "string"},
    {"name": "phone", "type": "string"},
}
```





Es un formato de almacenamiento columnar que surge de la colaboración de Twitter y Cloudera. Los datos se almacenan en formato binario y al final del archivo se agrega la metadata (schema). Este formato es ideal para agregaciones AVG, SUM, etc.



# Resumen



Properties	CSV	<b>JSON</b>	Parquet	Avro
Columnar	X	×	V	×
Compressable	<b>V</b>	<b>V</b>	<b>V</b>	<b>V</b>
Splittable	<b>V</b> *	<b>V</b> *	<b>V</b>	~
Readable	<b>V</b>	<b>V</b>	×	×
Complex data structure	X	V	<b>V</b>	<b>V</b>
Schema evolution	X	×	<b>✓</b>	<b>V</b>
			1 . 1	

## Herramientas de comprensión de datos





- gzip org.apache.hadoop.io.compress.GzipCodec
- bzip2 org.apache.hadoop.io.compress.BZip2Codec
- LZO com.hadoop.compression.lzo.LzopCodec
- Snappy org.apache.hadoop.io.compress.SnappyCode
   c
- Deflate org.apache.hadoop.io.compress.DeflateCodec



#### Ejemplo de Parquet y Snappy

In general LZO wins size benchmarks, Snappy good balance between size and CPU intensity.

```
led-zeppelin-albums.parquet/
```

- SUCCESS
- \_common\_metadata
- metadata
- Year=1969/
  - Part-r-00000-6d4d42e2-c13f-4bdf-917d-2152b24a0f24.snappy.parquet
  - Part-r-00001-6d4d42e2-c13f-4bdf-917d-2152b24a0f24.snappy.parquet
  - ...
- Year=1970/
  - Part-r-00000-35cb7ef4-6de6-4efa-9bc6-5286de520af7.snappy.parquet
  - ...



## RESUMEN DE LA CLASE

- ✓ Formatos de almacenamiento
- ✓ Formatos de elección
- ✓ Herramientas de comprensión de datos

